



NOSIAKADEMIA



RELATÓRIO DE ESTÁGIO

Área: Tecnologia de Big Data - NOSiCloud

Estagiário: Bruno Marques Henriques Veiga

18 de Julho de 2023

NOSi

Várzea/Praia/Santiago

Sumário

Identificação do Estágio.....	3
1 Introdução	4
2 Enquadramento	4
3 Identificação da Instituição.....	5
4 Desenvolvimento do Estágio.....	5
4.1 Área de Estágio	7
4.2 Objetivo	8
4.3 Metodologia.....	9
4.5 Cronograma	10
4.6 Descrição das tarefas realizadas	12
4.7 Resultados (Esperados/Realizados).....	16
5 Considerações Finais.....	20
6 Bibliografia	21

Identificação do Estágio

Empresa – NOSi (Núcleo Operacional da Sociedade da Informação)

Setor Estagiado – NOSiCloud

Diretor (a) / Coordenador (a) – Lamine Delgado

Área – Tecnologia Big Data

Estagiário (a) – Bruno Marques Henriques Veiga

Supervisor (a) – Paulo Fernandes

Mentor (a) – Patricio Carvalho

Local – Data Center, Praia, Cabo Verde

Ano – 2023

Duração – 6 meses

Período – 16 de Fevereiro – 16 de Agosto

1 Introdução

Este relatório tem por finalidade apresentar o desenvolvimento do estágio profissional que realizei no quadro da 14ª edição do estágio profissional do Nosiakademia, realizado de 16 de fevereiro a 16 de agosto de 2023, na Praia.

Começarei pelo enquadramento e pela identificação da instituição em que realizei o estágio. Apresentarei de seguida, o desenvolvimento do estágio em Tecnologia de Big Data por dentro da NOSiCloud. Nomeadamente falarei: da área de pesquisa, os objetivos, a metodologia, o cronograma, a descrição das tarefas realizadas, e os resultados (esperados/obtidos). Analisarei também a minha participação como estagiário e terminarei com algumas considerações e conclusões finais sobre os resultados obtidos.



2 Enquadramento

Surgiu uma oportunidade de estagiar no NOSi na abertura de vagas, em Outubro de 2022, para a realização da 14ª edição do estágio profissional do Nosiakademia. Nesta edição foram selecionados 96 estagiários para serem capacitados com uma duração prevista de 6 meses, em diversas áreas, principalmente relacionadas à tecnologia e também à gestão.

O estágio teve início a 16 de fevereiro de 2023, com uma formação inicial nas instalações do NOSi, na Várzea, que incluiu módulos de formação nas diferentes áreas de atuação do NOSi e das ferramentas utilizadas nesses departamentos.

Após esta primeira etapa de formação, com a duração de um mês, nós os estagiários fomos colocados em diferentes áreas de pesquisa. Fui colocado no departamento NOSiCloud, a cargo do diretor Lamine Delgado, sob a mentoria de Paulo Fernandes e de Patrício Carvalho. Neste setor, fiz o estágio na tecnologia Big Data.

3 Identificação da Instituição

O NOSi, Núcleo Operacional para a Sociedade da informação, criado em 2004, tem como missão liderar a transformação digital no setor público cabo-verdiano para melhorar a vida dos cidadãos e promover colaborações inovadoras entre as empresas. Esta instituição já tem mais de 20 anos de experiência na área da governação digital e tem desenvolvido soluções inovadoras tanto para o setor público quanto para o setor privado, atuando também nos mercados internacionais.

O NOSi tem se envolvido em diversos projetos inovadores tais como a criação das praças digitais (Konekta), que proporcionaram acesso gratuito à internet, facilitando a vida das pessoas. Implementou o serviço de solicitação e emissão de certidões online, o que reduziu as deslocações e o tempo de espera. NOSi também criou o portal Casa do Cidadão (www.portondinosilhas.cv), que possibilitou consultas e transações com os serviços públicos, tanto para residentes em Cabo Verde como para os que residem fora do país, tanto presencialmente quanto online.

O NOSi também expandiu suas atividades para além de Cabo Verde, participando de projetos em Moçambique, Guiné Equatorial e São Tomé e Príncipe.

Com foco na capacitação, lançaram a NOSi Akademia, um programa que oferece principalmente estágios profissionais para desenvolver a empregabilidade.

Além disso, o NOSi desempenhou um papel fundamental na criação do novo cartão nacional de identificação, e entre outras.

O seu trabalho foi reconhecido através de prémios, como a vitória na 3ª edição do Prémio Africano de Inovação para o Setor Público (AAPSIA 2012). Em 2019, o presidente da República, Dr. Jorge Carlos Fonseca, concedeu ao NOSi a primeira classe da medalha de mérito, honrando as suas contribuições.

Para NOSi esta em curso a implementação de uma ambiciosa Agenda Digital. O desafio do NOSi é de continuar a acelerar o desenvolvimento e que o País se transforme em uma nação verdadeiramente digital e competitiva a escala global.

Com o NOSi mais de 100 soluções E-Gov já foram desenvolvidas em diferentes áreas como: Ambiente Negócio, cidadania, educação, eleições, finanças, identificação e justiça, investimentos, poder local, saúde, segurança social, território, turismo e formações.

O NOSi está organizado em direções funcionais e áreas de projetos. As estruturas orgânicas e funcionais são flexíveis e orientadas aos projetos, para responder de forma ágil e adequada às atividades do NOSi, sujeitas a permanente mudança.

4 Desenvolvimento do Estágio

De 16 de fevereiro a 24 de março, realizou-se uma formação geral sobre as diferentes áreas de atuação do NOSi e algumas das ferramentas utilizadas.

DIAS	DATA	MÓDULOS FORMAÇÃO	ÁREA RESPONSÁVEL	LOCAL
2 dias	16 e 17 de Fevereiro	Formação Office Automation	NOSITSM	Piso 1 - NOSiAkademia
1 dia	20 de Fevereiro	EasyRedMine(agile)	APMG/GOIT	
3 dias	23 a 27 de Fevereiro	Analytics	BIS/STEM	
2 dias	28 e 01 de Março	Cloud Computing	Área de projetos NOSiCloud	
4 dias	02 a 07 de Março	Odoo & Python	DFPRI/GOIT	
3 dias	08 a 10 de Março	IGRPWEB	DID	
4 dias	13 a 16 de Março	Redes(cisco)	RCA e CNS	
3 dias	17 a 21 de Março	Ethical Hacking	Direção Segurança e Compliance	
3 dias	22 a 24 de Março	liferay	DID	

Depois desta ação inicial, cada estagiário foi colocado numa área de pesquisa e formação diferente. No meu plano de estágio fiquei integrado na área de tecnologia Big Data, uma tecnologia emergente da computação nuvens. Comecei o meu estágio no Departamento NOSiCloud, no dia 5 de abril de 2023.

A especialização em Big Data por ser nova no NOSiCloud, o programa de estágio não seria uma estrutura rigidamente definido. Pelo contrário, o plano de estágio seria adaptável. Também, por meio das minhas pesquisas, teria a oportunidade de fazer sugestões.

Assim, conduzi a maior parte das pesquisas de forma independente, focando em pensar como essa área poderia se integrar aos projetos do NOSi.

Infelizmente, devido à complexidade de ter várias disciplinas diferentes, não foi possível mergulhar na aplicação prática de um projeto real no período desse estágio, exceto pela instalação do framework Hadoop. Isso ocorreu porque o nível de aprendizado e pesquisa necessário foi longa e ocupou a totalidade do período de estágio.

Ao longo do estágio, familiarizei-me com o conceito de Big Data, mergulhei na compreensão da arquitetura em Big Data. Dediquei-me na compreensão do framework Hadoop e suas tecnologias e funcionalidades.

A instalação do Hadoop foi um processo extenso, repleto de fases de testes e debugging. A instalação requereu muita precisão.

Minhas pesquisas também se estenderam aos tipos de base de dados não relacionais, onde investiguei as vantagens e desvantagens de cada um deles, bem sobre como operar com essas bases de dados (HBase, MongoDB, Cassandra).

A transição para um projeto prático e real exigiria a conexão sinérgica de várias ferramentas. Isso engloba ter o hadoop instalado e todas as suas funcionalidades internas e externas, a habilidade de capturar e realizar a ingestão de dados conforme o tipo de fonte, o armazenamento nas bases de dados apropriadas. Também se os tipos de dados forem dados gerados em tempo real (streaming) é preciso de obter e utilizar ferramentas como apache spark streaming, kafka, storm ou flink. Adicionalmente, é preciso possuir proficiência em Python e SQL para desempenhar com várias dessas aplicações. O tempo de estágio não foi suficiente para poder resolver na prática um problema real infelizmente. Não obstante foi possível teoricamente desenhar como se interligam os demais processos para a captura, ingestão, armazenamento, processamento e análise de dados.

Durante o estágio, encontrei diversos desafios. Estes incluíram apresentações de Provas de Conceito (PoCs), estabelecer conexões e colaborações com os membros da equipe de estagiários e profissionais da NOSi, bem como adaptar-me ao ambiente de trabalho profissional. Além disso, houve o desafio de incorporar-me à minha área de pesquisa, garantindo uma pesquisa eficaz das diferentes disciplinas.

4.1 Área de Estágio

NOSiCloud (DON), o departamento onde eu estagiei, é o departamento de computação em nuvens.

Computação em nuvens segundo o NIST (US National Institute of Standards and Technology) é “o fornecimento de recursos computacionais sob demanda – tudo desde aplicativos a data centers pela internet em um base de pagamento por uso.”

O fornecimento desses recursos computacionais (IaaS, SaaS, PaaS) acontece de uma forma flexível. O cliente através de computação nuvens, terá a vantagem de utilizar recursos de uma empresa que especializa nesses fornecimentos computacionais então o cliente pode pagar só pelo recurso utilizado e o tempo necessário. A direção de Operações NOSiCloud (DON) é a área responsável pela gestão e implementação desses serviços, tanto para o setor público como para o setor privado.

Esta direção está em contacto com todas as outras áreas de projeto em especial a Direção Data Center (DDC) e Direção de Redes e Comunicação de Acesso (RCA), sobretudo com a área Core Data Center / Cloud Networking.

A DON é dividida em duas subáreas: Cloud Native Architectures (CNA) e Storage and Data Management (SDM).


Cloud Native Architectures (CNA) é dividida em 3 subáreas: a área que administra serviços de infraestrutura, serviços cloud e serviços core. Storage and Data Management (SDM) é a área que tem a responsabilidade de gerir a infraestrutura tecnológica de base de dados que suporta as aplicações e-GOV da rede do Estado.

A tecnologia de Big Data destaca como uma nova especialização dentro do âmbito do departamento DON. Essa especialização concentra-se na resolução dos desafios relacionados a ingestão, armazenamento e processamento de grandes volumes de dados, tanto não relacionais quanto relacionais, e também dados com alta velocidade de maneira eficiente para os poder analisar.

A área de tecnologia de Big Data cria um relacionamento próximo entre o departamento NOSiCloud (DON) e o departamento Business Intelligence (BIS). Trabalham em sinergia nas diferentes fases do processo de análise de Big Data.

Sendo uma área nova ainda a estrutura não está definida, mas a ideia é que as duas áreas vão trabalhar nas diferentes fases. O processo engloba extrair dados das diferentes fontes, criar pipelines para ingestão, armazenamento e processamento de dados, detetar anomalias, analisar e consultar os dados com SQL e Python, responder perguntas, e tomar decisões inteligentes

baseados nos dados. Essas são algumas das fases. A imagem seguinte demonstra as diferentes fases/tarefas relacionadas com a coleta de dados não tratados, até a otimização com machine learning em um diagrama criado por Monica Roga.



4.2 Objetivo

Atualmente, as empresas produzem volumes substanciais de dados, abrangendo dados estruturados, dados semiestruturados e dados não estruturados.

Os métodos tradicionais de tratar dados não suportam a grande variedade, volume e a velocidade dos dados atual. Então se faz sentir a necessidade de coletar, armazenar, processar e analisar esses dados.

Existe várias aplicações para tomada de decisões que se pode desenvolver através de análise desses dados. Alguns exemplos são: análise de dados em tempo real, personalização e recomendação, previsão e modelagem preditiva, identificação de padrões, análise de fraudes, marketing e publicidade segmentado, otimização, monitoramento, detecção de anomalias e etc.

As aplicações de tecnologia de Big Data tem funcionalidades tanto para: setor de medicina e saúde, ciência e pesquisa, setor de finanças, setor público, na educação, na mídias e entretenimento, os consumidores e negócios. Novas aplicações através da tecnologia Big Data continuam surgindo com a necessidade e a evolução tecnológica.

Para consumidores Big Data tem benefícios como por exemplo em mecanismos de recomendações. Em empresas Big Data tem benefícios como por exemplo em identificação de fraudes, fazer previsões, marketing segmentado ao publico alvo, decisões baseadas em dados. Por último em pesquisas, um exemplo é quando tecnologia Big Data permitiu identificar surtos de gripe nos Estados Unidos muito mais rápido que os estudos do centro de controle de doenças, através de pesquisas de palavra "gripe" no Google. Também em pesquisas através de tecnologia de Big Data permite fazer estudos com um número de dados maior.

Assim sendo, o objetivo do estágio é aprender a produzir valor a partir desses dados desde o seu formato não tratado, e ser capaz de formar respostas inteligentes e rápidas baseadas nesses dados.


No documento oficial de estágio proposto pelos mentores e supervisores assim está descrito os objetivos gerais e objetivos específicos do estágio:

Objetivo Geral: O estágio tem como objetivo montar um sistema Big Data que irá coletar armazenar, processar e analisar os dados através da implementação.

Objetivos Específicos:

O estágio tem os seguintes objetivos específicos:

- Conhecer os fundamentos da tecnologia Big Data
- Estudar e compreender as diversas implementações disponíveis do Big Data
- Estudar o conceito de datawarehouse e as suas valências
- Estudo e implementação da plataforma Hadoop



4.3 Metodologia

Após a primeira etapa da formação ministrada pelos formadores do NOSi, e de ter sido colocado no departamento do NOSiCloud, pesquisei vários temas relacionados com a minha área de estágio, nomeadamente:

Introdução a computação nuvens;

Conceito e os fundamentos da tecnologia Big Data;

Arquitetura Big Data;

Data warehousing;

Linguagem Python;

Linux command line;

Instalação do framework hadoop em cluster de quatro máquinas;

Framework open source Hadoop e diferentes funcionamentos da sua tecnologia;

Base de dados não relacionais como HBase, MongoDB e Cassandra;

A pesquisa foi feita de forma independente, tendo-me servido de vídeo aulas e artigos, participado em fóruns online, e com a orientação dos mentores que me ajudaram a avançar nos diferentes desafios do estágio.

4.4 Cronograma

O plano do estágio foi concebido com flexibilidade, dada a tecnologia Big Data ser uma área nova no NosiCloud.

O cronograma oficial na figura a baixo deu início a minha trajetória de estágio. Com a conclusão desses marcos, novos objetivos seriam considerados para orientar a próxima fase de minha jornada no estágio.

3. Conteúdo Programático do Estágio

Objetivo	#	Conteúdo Programático	Âmbito	Área Suporte
1. Fundamentos da tecnologia Big Data	1.1	Conceitos tecnológicos		DON
	1.2	Arquitetura Big Data		DON / BIS
	1.3	Data Warehouse		DON / BIS
2. Hadoop	2.1	Definições técnicas		DON / BIS
	2.2	Arquitetura e Funcionalidades		DON / BIS
	2.3	Implementação		DON / BIS

O cronograma marca os pontos chave, entretanto, a medida que aprofundarmos nos estudos desses elementos, complementamos/preenchemos com novas pesquisas que conectam os conhecimentos e enriquecem o nosso percurso.

Tanto (1.) Fundamentos da Tecnologia Big Data e (2.) Hadoop foram objetivos concluídos, assim completando as etapas do cronograma inicial.

Além disso, incorporei novos tópicos ao meu programa, guiado por necessidade ou orientação dos mentores. Como por exemplo dediquei-me a fazer uma breve introdução a computação em nuvem, que é o ambiente onde tecnologia Big Data atua.

Também me dediquei a linguagem Python, sendo Python a linguagem base para lidar com diferentes aplicações da tecnologia Big Data. Também tive a oportunidade de participar com o departamento BIS em um projeto de análise de dados, onde fui introduzido a biblioteca Pandas.


Além disso, absorvi conhecimentos de forma indireta, por exemplo, a instalação do Hadoop aprimorou minha proficiência na linha de comando. Linha de comando também é uma área que vim a descobrir ser essencial para a área tecnologia de Big Data.

Depois de eu ter avançado no cronograma, um novo objetivo emergiu mais no estágio. Análise de dados do HProxy – um projeto real. Isso deu origem a um novo percurso de metas, visando solucionar essa problemática.

A instalação do Hadoop foi concluída, mas foi desafiadora. Descobri que a instalação ia demorar mais do que o previsto. Assim, essa instalação duradoura foi uma barreira significativa para o alcance dos objetivos. Isso me conduziu à reflexão também sobre minhas próprias ineficiências e como poderia avançar com maior celeridade. Os meus mentores enfatizaram a escassez de tempo.

Além disso, em adição a instalação de Apache Hadoop, as outras funcionalidades do ecossistema de framework de Hadoop devem ser instaladas também através da instalação Apache open source.

No entanto, segui para os restantes objetivos estudando as próximas fases do processo necessários a análise de Big Data. Mudei o meu foco para a parte de armazenamento de dados. Familiarizei tanto com os bases de dados não relacionais e processamento com datawarehouse através de Hive. No fim, estudei os diferentes benefícios e casos de uso que posso conseguir através de análise de dados de HProxy. Assim completei o meu percurso.



4.5 Descrição das tarefas realizadas

Formação geral

A formação inicial geral no 1º mês de estágio foi-nos dito que foi uma introdução nova nos estágios profissionais. Antes os estagiários eram alocados diretamente na área em que iam atuar.

Através de uma formação geral fomos introduzidos a diferentes áreas funcionais do NOSi, conhecendo os profissionais destas áreas. Eles nos deram uma formação introdutória a área, trabalhamos em diferentes exercícios com algumas das ferramentas utilizadas nestas áreas funcionais. Foi envolvente ter essa experiência com as diferentes áreas funcionais. Através dessa formação fiquei com uma visão mais ampla dos diferentes eventos em uma organização e de como interagem entre si. Eu sendo da área de tecnologia, também as formações me ajudaram a adaptar, experienciar e reconhecer, as ferramentas e os projetos em que atuo com mais motivação. Um outro ponto benéfico desta formação inicial também foi pela adaptação social com os demais estagiários e diferentes profissionais do NOSi.

Computação nuvens

Os meus estudos na disciplina de computação nuvens construíram uma base para a minha especialização em Big Data. Também me ajudou a familiarizar com diferentes termos utilizados no departamento. Tentei perceber a relação que existe entre computação nuvens e tecnologia Big Data. A tecnologia Big Data juntamente com Blockchain, Internet das coisas e Inteligências artificiais são tecnologias emergentes da computação nuvens.

Conceito Big Data

Em fundamentos de Big data fiz um curso introdutório chamado “Fundamentos do Big Data: Técnicas e Conceitos” através de LinkedIn com um certificado final. Foi por recomendação do mentor.

Este curso foi muito informativo e me esclareceu sobre os conceitos fundamentais de Big Data. Os temas que foram introduzidos neste curso foram: O que é Big data? Como é utilizado em negócio, para consumidores e em pesquisas. Estudei sobre as fontes de estruturas do Big Data. Dados estruturados e não estruturados e semiestruturadas. Dados gerados por máquinas e gerados por humanos. Neste curso também estudei sobre o armazenamento de Big Data, como rede de área de armazenamento, SAN, e armazenamento em nuvem. Os serviços oferecidos como IaaS, PaaS, SaaS, DaaS. Vi exemplos de análise de Big Data como: Monitoramento e detecção de anomalias, mineração de dados e análise de texto, análise preditiva, visualização de Big Data.

Um outro tema foi a ética no Big Data. Os desafios com o anonimato, desanimação de dados e desafios com a confidencialidade. Vi também que há desafios envolvendo a qualidade dos dados. Então é importante a preparação de dados para análise. Estudei sobre o conceito de extração, transformação e carregamento no Big data e como no Big Data o Hadoop é responsável por isso.

Python, Pandas

Neste estágio também foquei em fazer uma revisão e praticar Python. A linguagem Python tem uma grande importância para um profissional em Big Data. É a linguagem de programação que é amplamente usada. Usa-se Python para interagir com muitas das tecnologias populares de Big Data, como Mapreduce, Hive, HBase e Cassandra. Também Python oferece bibliotecas como NumPy, pandas e matplotlib que permitem os profissionais de Big data a manipular e analisarem o grande volume de dados com eficiência.

A partir de formação geral do estágio fui introduzido a revisões e recursos de ensino de Python e no decorrer do estágio completei 1/3 de um curso em linguagem Python. Também tive a oportunidade de participar em um projeto com os estagiários do departamento BIS, em que utilizamos Pandas, NumPy e matplotlib para analisar dados.

Durante o estágio dei ao estudo do Python uma segunda prioridade, dando mais importância no seguimento das diferentes fases da arquitetura de Big Data e de estudar a ferramenta Hadoop.

Quanto aos exercícios de Pandas/Python, foram desafiantes e ainda preciso de continuar a minha pesquisa e prática nas linguagens para poder ter recursos suficientes para resolver exercícios

Arquitetura Big Data

A Arquitetura de Big Data refere-se a passos detalhados de um conjunto de princípios, práticas, tecnologias, métodos, e componentes utilizados para lidar com grandes quantidades de dados, a complexidade de dados e a velocidade desses dados.

A arquitetura de Big Data ajudou-me a perceber a dimensão da tecnologia Big Data. Percebi que existe diferentes componentes que especializam em lidar com as diferentes fases, camadas e objetivos no processo de análise de Big Data.

Tecnologia Hadoop

O Hadoop é um framework que ajuda aplicações a serem desenvolvidos no conceito de computação distribuída. Hadoop é a camada entre o usuário e o cluster de computadores.


Com o crescimento do internet e o aumento de dados no mundo, tornou-se impossível depender no aumento do poder computacional de um computador para esses dados enormes. Com a grande quantidade de dados e que esta constantemente crescendo, um framework distribuído que usa um cluster de computadores é a solução para esses cenários.

Estudei os componentes principais que formam o núcleo do Hadoop: **Hadoop Distributed File System (HDFS)** que é inspirado em Google File System e **MapReduce Framework** que é inspirada em Google MapReduce. Também estudei a tecnologia de YARN que foi introduzido no Hadoop a partir da versão 2.x e também uma parte core de Hadoop.

Hadoop é um framework open source é livre para qualquer pessoa usar através de Apache Foundation. Também qualquer um pode usar, modificar e distribuir. Hadoop oferece versões comerciais também com pacotes adicionais, suporte técnico e etc.

Ecossistema Hadoop

Hadoop sendo um software open source e tendo vários contribuintes, Hadoop fornece uma grande família de funcionalidades. Hadoop fornece funcionalidade para todas as fases constituídas em uma arquitetura de Big Data.



Neste estágio eu não tive a possibilidade de familiarizar-me com todas as ferramentas no ecossistema de Hadoop.

Suplementando os componentes principais de Hadoop, foquei mais nas funcionalidades de armazenamento e processamento.

Instalação Hadoop

Conclui a instalação de Hadoop cluster distribuído em 4 máquinas. **A documentação da minha instalação de Hadoop esta em anexo.** Passei pelas 3 fases de instalação. Standalone e pseudo-distribuido que é a instalação em um só computador simulando a instalação real com o objetivo de fazer testes e debugging.

Depois, avancei para a instalação de distribuição completa, que é o modo de produção. Usei 4 máquinas para a distribuição. No entanto é escalável quando se necessitar de mais armazenamento e processamento.

A instalação foi um processo longo. As complexidades de instalar um programa open source incluem: garantir a compatibilidade entre as funcionalidades e as versões, falta de documentação detalhada sobre o processo de instalação, a configuração tem de ser precisa, e etc. Eu tive uma grande ajuda dos fóruns online onde tive partilha de profissionais da área via internet.

Ambari fornece uma interface intuitiva para o uso de Hadoop e é uma ferramenta de gestão. Mas quando terminei a instalação de Hadoop descobri que o Ambari devia ser instalado antes do Hadoop e através do Ambari poderia fazer a instalação de Hadoop. Então não foi possível instalar Ambari. Mas também tem outras opções. Descobri que a gestão pode ser feita tão facilmente também com ferramentas como Ansible.


Base de dados Não Relacionais e Data Warehouse

Avancei os meus estudos para a fase de armazenamento. As aplicações quando necessitam de acesso aos dados, vai encontrara-los armazenados nas bases de dados. Existe 2 categorias gerais de base de dados: Base de dados não relacionais e base de dados relacionais. Neste estágio foquei nas bases de dados não relacionais, desde que são mais apropriados quando se trata de Big Data. Algumas características que descrevem um base de dados não relacional são: a flexibilidade, escalabilidade, tolerância a partições, e rapidez.

As bases de dados não relacionais que estudei são: MongoDB, HBase e Cassandra.

HBase ao contrário dos outros pertence a Hadoop. É construído em cima do HDFS. Então para armazenar dados massivos HBase usa HDFS para a tecnologia de distribuição. HBase é construído por trás das ideias do Google Big Table.

Outro exemplo, Hive é um datawarehouse para grande quantidade de dados e tem uma linguagem analítica avançada chamada HQL que é similar a SQL para análise/processamento de dados.



4.6 Resultados (Esperados/Realizados)

Os resultados esperados seria conseguir analisar os dados de projetos reais da organização NOSi e conseguir produzir valores e benefícios para a organização. No caso do meu estágio o objetivo proposto pelos meus mentores era de usar a tecnologia Big Data para analisar os dados de tráfego de entrada no Data Center.

Através de análise de todo o tráfego de entrada no Data center poderia conseguir benefícios como:

- **Reconhecer padrões e preferências no comportamento do usuário.** Através desses padrões pode surgir ideias para aprimorar os serviços e adaptá-los de acordo com as necessidades dos clientes. Sugerir aos negócios quais a priorização de investimentos de acordo com as preferências dos clientes.
- **Busca de padrões suspeitos e picos de tráfego inesperado** ajudando a detecção de segurança e anomalias.
- **Otimização através de identificação de padrões de inconsistências, congestionamentos ou ineficiências.** Melhorando o desempenho geral do sistema, ou otimizando os recursos e assim reduzindo os custos.
- **Planeamento da capacidade.** Através de registos históricos de HAProxy é possível projetar padrões de crescimentos futuros.

Esses objetivos são os resultados que esperava alcançar. Consegui alcançar vários objetivos no estágio entendendo várias novas tecnologias, mas para alcançar esses objetivos faltaram pesquisar sobre algumas mais funcionalidades, e não só mas entender como elas se encaixam uma com as outras.

Para analisar os dados de HAProxy temos de montar um sistema que resolva esses problemas específicos com as tecnologias certas.


Para descobrir o sistema certo temos de saber como abordar o problema:

- Qual é o tamanho dos dados?
- Você realmente precisa de um cluster?
- Qual a infraestrutura interna da organização e a experiência que tem disponível?
- Você precisa manter esses dados para sempre para auditoria? Ou você precisa limpá-lo frequentemente para privacidade?
- Qual são os requerimentos de segurança?
- Com que rapidez os usuários finais precisam obter uma resposta?
- Milissegundos? Então HBase ou Cassandra será necessário.
- As consultas podem ser baseadas em dados antigos? De um dia? Um minuto? Hive / Pig / Spark.
- Ou precisa de ser processados quase em tempo real? Spark Streaming / Storm / Flink com Kafka ou Flume.
- Também é bom pensar as coisas um pouco a prova do futuro. Em Big Data mover os dados de um repositório para o outro é uma tarefa árdua.
- A organização possui componentes existentes que você pode usar?
- Qual é a menor quantidade de infraestrutura que você poderia construir?
- O que é mais valorizado nas bases de dados: Disponibilidade, tolerância a partição ou consistência?

Através de responder essas perguntas a ideia das tecnologias a serem utilizadas e do sistema a construir ficara mais claro. Não existe uma solução, pode haver várias.

Alguns exemplos de soluções de sistemas montados são:

Figura 1: Exemplo de um sistema que devolve os top 10 melhores produtos vendidos.



Descrição: Quando um usuário faz as compras, com **Flume** que depende de **zookeeper** para funcionar, esses dados são canalizados para **spark streaming** que vai trabalhar continuamente calculando os top produtos mais vendidos para cada categoria, e os resultados são armazenados

em **Cassandra**. A partir daí a aplicação web tem acesso a base de dados Cassandra, para responder quais são os 10 produtos mais vendidos.

Essas tecnologias utilizadas nessa arquitetura são escolhidas a partir das necessidades da organização e dos usuários finais. É uma solução, mas pode existir outras soluções.

Cada uma dessas caixas podem ser um cluster de vários computadores dependendo do tamanho dos dados.

Como chegar nessa arquitetura? Por exemplo, sabemos que precisamos de base de dados não relacionais se tivermos milhares de consultas por segundo. Depois, dependendo do teorema de CAP (disponibilidade, consistência e tolerância a partição) escolhemos qual é a prioridade para o nosso caso de uso. Cassandra valoriza disponibilidade e tolerância a partição mais do que consistência. Então possa ser que hipoteticamente este seja a melhor opção. Por outro lado, também é importante considerar as práticas, tecnologias já usadas na organização. Porque a diferença entre os bases de dados não é enorme.

Em alguns casos de implementação de sistemas nem é preciso usar Hadoop. Por exemplo Spark Streaming tem servidor autônomo, mas se tiver Hadoop pode executá-lo sobre o Hadoop.

Conseguimos montar um sistema através de responder perguntas, cumprir os requisitos, conhecer as diferentes funcionalidades das tecnologias e as compatibilidades que existe entre si, e em conhecer as vantagens e as desvantagens de cada uma das tecnologias em relação ao objetivo a cumprir.

Outros exemplos de sistemas de análise de Big Data:

Figura 2: Exemplo de um sistema para contar sessões diárias.





Figura 3: Recomendação de filme para um site.



As funcionalidades que trabalham no processo completo de análise de Big Data são inúmeras. É preciso conhecê-las bem e assim escolher os componentes necessários fazendo as questões certas. Assim com os componentes certos e passando pelas diferentes fases montamos um sistema.

Os resultados esperados e realizados com o propósito de resolver um problema de análise de Big Data são:

Resultados esperados	Resultados realizados
Conceito de Big Data	✓
Tecnologia Hadoop	✓
Plataforma Hadoop instalada	✓
Entendimento Ecossistema Hadoop	✓
Funcionalidades Armazenamento	Em progresso
Funcionalidades Processamento	Em progresso
Funcionalidades Ingestão	x
Funcionalidades de Acesso	Em progresso
Funcionalidades Streaming	x
Linguagem Python (para interagir com as funcionalidades)	Em progresso
Instalação das diferentes funcionalidades (HBase, Hive, Spark)	x
Conhecimento SQL (para interagir com as funcionalidades)	x
Arquitetura de Big Data	✓
Linux Command Line	✓

5. Considerações Finais

Através da realização do presente estágio fui introduzido á uma área tecnológica nova despertando o meu interesse e entusiasmo.

O estágio é um investimento profissional e pessoal muito importante para o futuro, mas a dedicação constante é necessária.

No estágio, passei por desafios como apresentações de PoC, conhecer os diferentes membros dos estagiários e colaboradores no NOSi, integrar no ambiente de trabalho, e integrar-me na minha área de pesquisa. A pesquisa sendo feita de uma forma independente, foi vantajoso por me oferecer a liberdade de depender do meu esforço para dar o meu melhor tentando encontrando os melhores recursos, mas também foi muito desafiador por não ter com quem compartilhar. Mas os desafios são os nossos melhores amigos para o desenvolvimento. Através da oportunidade desse estágio o desenvolvimento profissional foi a nível de hard skills e também soft skills.

Ao concluir o meu relatório sinto que em determinados aspetos podia ser mais eficaz com o tempo de estágio, e ter avançado com mais rapidez com os objetivos finais em mente, mas inicialmente não tinha ainda uma compreensão panorâmica total de todas as fases necessárias. Priorizei sentir-me estável em cada fase do processo. Por outro lado, a dimensão das funcionalidades a adquirir são várias e também a instalação de Open source Frameworks como Hadoop apresentou muitos desafios.

Um grande marco foi ter concluído a instalação de Apache Hadoop em cluster. Também um grande marco para mim é poder ter entendido como as diferentes aplicações interligam entre si para formar uma arquitetura de Big Data.

Neste estágio, fiz uma pesquisa profunda do conceito e os fundamentos de Big Data, estudei sobre a arquitetura de Big Data, fiz revisões e desenvolvi o meu conhecimento na linguagem Python, pratiquei atividades com Linux command line, instalei o framework hadoop em cluster de quatro máquinas. Ganhei conhecimento do framework open source hadoop e de como a sua tecnologia funciona. Estudei sobre base de dados não relacionais como HBase, MongoDB e Cassandra. Ganhei conhecimento das diferentes fases de análise de dados como de ingestão de dados, armazenamento, processamento e visualização e de como esses componentes interagem entre si. Ganhei conhecimento dos motivos de usar aplicações streaming e das tecnologias que lidam com dados streaming. E por fim entendi a canalização das diferentes fases, desde a coleção dos dados não tratados, até a visualização dos insights. Por último entendi os benefícios de análise de Big Data.

Com esse pequeno investimento que fiz neste estágio e com um contínuo crescimento e dedicação as portas podem abrir, em carreiras como Engenheiro de Big Data, Engenheiro de Dados, ou Analista de Dados, e sou muito grato a isto.

5 Bibliografia

[Fundamentos do Big Data: Técnicas e Conceitos \(linkedin.com\)](#)

[Getting started with Hadoop \(linkedin.com\)](#)

[Free Big Data Tutorial - Big Data and Hadoop Essentials | Udemy](#)